



Instituto Nacional para Convergência Digital

INCoD



ISSN 2236-5281

Technical Report

INCoD/LAPIX.02.2024.P

DOI: [10.13140/RG.2.2.32290.03520](https://doi.org/10.13140/RG.2.2.32290.03520)

Revisão Sistemática do Uso de Inteligência Artificial Gerativa na modelagem 3D para Desenvolvimento de Jogos

Autores:
Emily Sayuri Kiba
Aldo von Wangenheim

Version 1.0
Status: Final
Distribution: External
JUNHO - 2024

Sumário

1.	<i>INTRODUÇÃO</i>	3
2.	<i>REVISÃO SISTEMÁTICA</i>	3
2.1	Termos de Busca	3
2.2	Critério de Inclusão e Exclusão	4
2.3	Execução de Busca	4
3.	<i>RESULTADOS</i>	5
3.1	“MVDream: Multi-view Diffusion for 3D Generation”	5
3.2	“One-2-3-45++: Fast Single Image to 3D Objects with Consistent Multi-View Generation and 3D Diffusion”	6
3.3	“GenesisTex: Adapting Image Denoising Diffusion to Texture Space”	7
3.4	“Material Palette: Extraction of Material from Single Image”	8
3.5	“Curso de Stable Diffusion”	9
3.6	“Creating 3D Parallax Type Images With Automatic1111 Stable Diffusion WebUI & Depth Maps”	10
3.7	“Image to 3D - 3D AI generation for GameDev Experiment”	11
3.8	“Creating Procedural Materials Using AI & Substance 3D Designer”	12
3.9	“Meshy AI : a 3D AI Model Design Generator”	13
3.10	“Luma Genie 3D Character”	14
3.11	“How Upland Accelerated Their 3D Asset Production by 70%”	15
4.	<i>CONCLUSÃO</i>	16
5.	<i>REFERÊNCIAS</i>	17

1. INTRODUÇÃO

Atualmente na indústria de jogos eletrônicos, a modelagem 3D desempenha papel crucial na criação de mundos imersivos, realísticos e artísticos. E por isso, a evolução dos jogos eletrônicos tem sido marcada por avanços tecnológicos que elevam a qualidade visual e criatividade dos elementos de jogo. No entanto, na criação de objetos ou ambientes com modelagem 3D requer considerável esforço técnico e artístico. Alguns *game engine* como Unity e Unreal facilitam o desenvolvimento desses ambientes e objetos, porém a necessidade de eficiência no processo de modelagem 3D ainda continua sendo desafio para desenvolvedores de jogos.

Nesse contexto, a inteligência artificial (IA) gerativa tem emergido recentemente como uma solução promissora para aprimorar o processo complexo de modelagem 3D. A aplicação de IA gerativa na modelagem 3D pode variar desde geração de imagem como ideia de personagem ou ambiente, texturização até gerar própria modelagem. Além disso, essas ferramentas baseadas em IA gerativa não apenas possibilitam criações inovadoras, mas também reduzem o tempo necessário para criar modelos detalhados. No entanto, apesar do grande potencial, a adoção de IA gerativa na modelagem 3D ainda enfrenta diversos desafios e limitações.

Dada a evolução de IA gerativa e suas aplicações na modelagem 3D, esta revisão sistemática tem objetivo de analisar literatura e projetos existentes sobre o tema, identificando as abordagens mais promissoras, desafios enfrentados e tendências emergentes. Assim, auxiliando para desenvolvedores de jogos que querem eficiência e criatividade no processo de modelagem 3D.

2. REVISÃO SISTEMÁTICA

Para orientar essa revisão sistemática, foi utilizado a seguinte estrutura.



Figura 1: Procedimento geral de revisão sistemática

2.1 Termos de Busca

Nas pesquisas foram realizadas uma abordagem “ad-hoc”, devido à falta de literatura acadêmica sobre esse tema. Essa abordagem permitiu uma busca mais abrangente e

flexível com fontes abertas. Assim, a pesquisa foi realizada a busca principalmente no Google Scholar, além de outros recursos online acessíveis ao público.

De acordo com as perguntas formuladas são utilizados seguintes termos de busca, seus sinônimos e traduções conforme a tabela.

Termos (inglês)	Sinônimos	Tradução
Generative artificial intelligence	-	Inteligência artificial gerativa
3D modeling	-	Modelagem 3D
Stable Diffusion	-	Stable Diffusion
Diffusion Model	-	Modelo de difusão
3D texture	-	Textura 3D
Diffuse stability	-	Estabilidade Difusa

Tabela 1: Tabela de Sinônimos e Traduções dos Termos de Busca

2.2 Critério de Inclusão e Exclusão

Nesta seção descreve a sintaxe de pesquisa, critério de inclusão e exclusão. Foram aplicados critérios de exclusão durante o processo de seleção dos artigos para garantir relevância para o tema. Dessa maneira, foram excluídos artigos que não utilizou IA gerativa para modelagem 3D, projetos que não são úteis para criação de jogo, estudos duplicados ou informações insuficientes para avaliação. Os critérios de inclusão foram definidos para incluir artigos que demonstram aplicação de IA gerativa para modelagem 3D de uma maneira eficiente, aplicação de IA gerativa para criação de texturas e IA gerativas para geração de imagens específicas que pode auxiliar na ideia de criação de jogo. A seguinte tabela demonstra o string de pesquisa utilizado.

#	Base	String de pesquisa
1	Google Scholar	(“Generative Artificial Intelligence” OR “Generative AI” OR “Artificial Intelligence” OR “Stable Diffusion”) AND (“3D models” OR “Blender” OR “3D”) AND (“Game engine” OR “Game design” OR “Game development” OR “Game” OR “Texture” OR “Assets”)

Tabela 2: Tabela de String de Pesquisa

2.3 Execução de Busca

Repositórios	Termos de busca	Total de resultado	Quantidade de artigos relevantes
Google Scholar	Stable Diffusion 3D modeling game	19600	3
arxiv	Diffusion PBR texture	4	1
medium	Stable Diffusion 3D	?	3
80lv	Artificial Intelligence 3D	389	1

Tabela 3: Tabela de Buscas e Resultados

3. RESULTADOS

3.1 “MVDream: Multi-view Diffusion for 3D Generation”

Autores: Yichun Shi, Peng Wang, Jianglong Ye, Long Mai, Kejie Li, Xiao Yang (2024)

Fonte: arxiv

Resumo: a pesquisa [1] introduz o [MVDream](#), um modelo de difusão projetado para gerar as imagens de visualização múltipla a partir de *prompt* de texto e com isso gera representação 3D de forma mais coerente. Em primeiro, o modelo aplica uma abordagem de auto-atenção inflada para 3D, ou seja, permite ao modelo entender melhor a cena com mais detalhes e gerar imagens mais consistentes. Além disso, *embedding* de câmera para cada visão que ajuda a compreender a perspectiva de cada imagem renderizada. Em seguida, realizaram treinamentos com combinação de 2D com 3D, com isso aprende a generalizar conceitos a partir de 2D e mantendo consistência na renderização no 3D em diferentes ângulos. Para otimizar a representação 3D e refinar processo de geração foi aplicado a técnica de *Score Distillation Sampling* (SDS) que realiza previsão com base na informação disponível, com isso produz resultado consistente e de alta qualidade. Por fim, realizou treinamento com DreamBooth [2], permitindo a personalização da geração 3D. A limitação desse modelo é a dificuldade de aplicar para imagens em situações diferentes do treinamento, podendo não ser flexível e adaptável quanto desejado. Assista ao vídeo do processo de geração 3D [aqui](#).

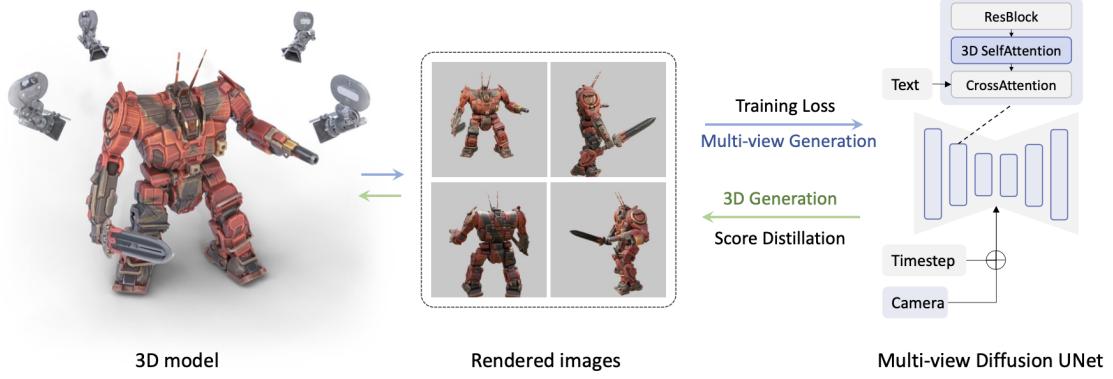


Imagen 3.1: Ilustração de modelo de difusão multi-visão



Imagen 3.2: Comparação de MVDream com texto-to-image-to-3D usando SDXL + Zero123-XL

3.2 “One-2-3-45++: Fast Single Image to 3D Objects with Consistent Multi-View Generation and 3D Diffusion”

Autores: Minghua Liu¹, Ruoxi Shi, Linghao Chen¹, Zhuoyang Zhang¹, Chao Xu, Xinyue Wei, Hansheng Chen, Chong Zeng, Jiayuan Gu e Hao Su (2023)

Fonte: arxiv

Resumo: neste artigo [3] apresenta [One-2-3-45++](#) um método que transforma uma única imagem em uma malha texturizada em 3D, aproximadamente em 1 minuto. É o modelo que supera as limitações do One-2-3-45 [4], oferecendo maior robustez e qualidade de geração do conteúdo 3D. Este método utiliza uma única imagem de entrada, segue duas etapas principais: geração de múltiplas vistas em 2D e reconstrução 3D. No primeiro estágio, em vez de prever cada perspectiva separadamente, como no Zero123 [5] (utilizado no modelo One-2-3-45), prevê imagens de vários ângulos de forma simultânea. Isso é alcançado combinando um conjunto de seis imagens de perspectiva diferentes em uma única imagem. Assim, o modelo de difusão 2D é ajustado para gerar esta imagem combinada, baseada na imagem de referência fornecida como entrada. Na segunda etapa, utiliza o módulo de difusão 3D condicionada pelas múltiplas vistas para prever a malha texturizada do objeto. Este processo ocorre de maneira gradual, refinando a forma do objeto de uma representação inicial mais geral até a malha detalhada e precisa.

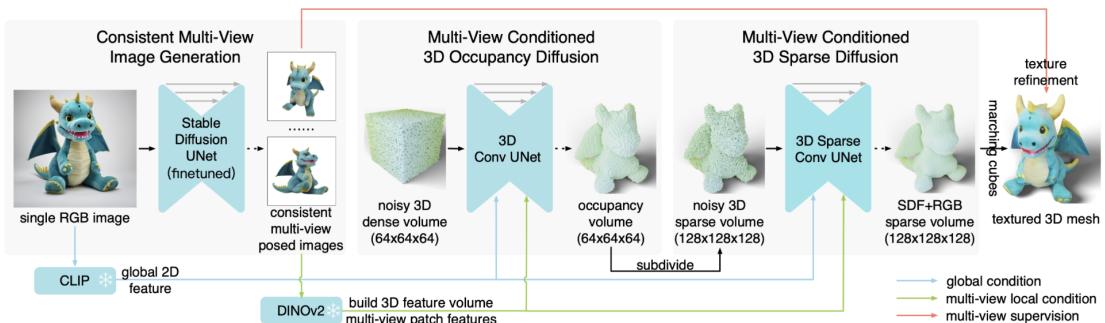


Imagen 3.3: As etapas de geração de conteúdo 3D com One-2-3-45++



Imagen 3.4: Aplicação de modelos 3D gerados pelo One-2-3-45++ no jogo

3.3 “GenesisTex: Adapting Image Denoising Diffusion to Texture Space”

Autores: Chenjian Gao, Boyan Jiang, Xinghui Li, Yingpeng Zhang e Qian Yu (2024)

Fonte: arxiv

Resumo: este artigo [6] apresenta [GenesisTex](#), um novo método para sintetizar texturas para geometrias 3D a partir de descrição de texto. Ele adapta um modelo pré-treinado de Stable Diffusion para o espaço de texturas por meio de amostragem. Este método mantém mapas de textura latente de múltiplas vistas durante o processo de amostragem e realiza remoção de ruído para melhorar a qualidade. Eles focaram em dois aspectos de consistência durante o processo de amostragem: a consistência global de estilo que incorpora consistência de estilo na rede de predição de ruído para garantir que o estilo seja coerente em todas as perspectivas geradas que ajuda manter uniformidade e a consistência local entre múltiplas vistas que usa alinhamento dinâmico das texturas latentes para assegurar que os detalhes fiquem alinhados entre diferentes ângulos, melhorando a qualidade geral das texturas. Devido a limitação de memória, a amostragem de espaço de texturas opera em vistas esparsas, portanto para melhorar qualidade, aplicaram a técnica de *inpainting* e img2img em vistas mais densas para refinamento do mapa de textura. No entanto, a limitação é o custo significativo de memória associado à manutenção da consistência do estilo, causado pela atenção cruzada. Essa limitação restringe o número de pontos de vista e requer etapas de pós-processamento, como *inpainting* e img2img.



Imagen 3.5: Resultado de texturas geradas por GenesisTex

3.4 “Material Palette: Extraction of Material from Single Image”

Autores: Ivan Lopes, Fabio Pizzati e Raoul de Charette (2023)

Fontes: arxiv

Resumos: esta pesquisa [7] propõe o método denominado Material Palette para extrair *Physically-Based-Rendering* (PBR) com única imagem de entrada operando de forma interativa com usuário ou de forma automatizada, como mostrado na Imagem 3.6. O PBR é uma técnica de renderização que representa materiais e superfícies de forma realista simulando a interação de luz com materiais. Na primeira etapa, empregou um modelo de difusão para mapear regiões da imagem de entrada para conceito de material, gerando imagens de textura que representam material da cena. Este processo aproveita bibliotecas de materiais sintéticos existentes com *Spatially Varying Bidirectional Reflectance Distribution Function* (SVBRDFs) conhecidos, o qual define como a aparência de uma superfície muda dependendo tanto da localização na superfície quanto das direções de incidência e reflexão da luz. Além de utilizar conjunto de texturas RGB geradas por Stable Diffusion treinando LoRA[8] Dreambooth[2] para permitir generalização para novos exemplos através de adaptação de domínio não supervisionada. Na segunda etapa, uma rede separada decompõe as texturas geradas em SVBRDFs, proporcionando materiais prontos para uso em aplicações de renderização. Um dos principais desafios encontrados reside na dificuldade de capturar materiais uniformes simples. Enquanto outros métodos tinham dificuldades em lidar com padrões complexos, o Material Palette, enfrenta problemas com materiais simples, resultando em artefatos de cor e degradação de qualidade. Além disso, as ambiguidades na iluminação apresentam-se como outra barreira, especialmente em superfícies sombreadas causando inconsistência de cor.



Imagen 3.6: A esquema de extração de materiais partir de uma única imagem

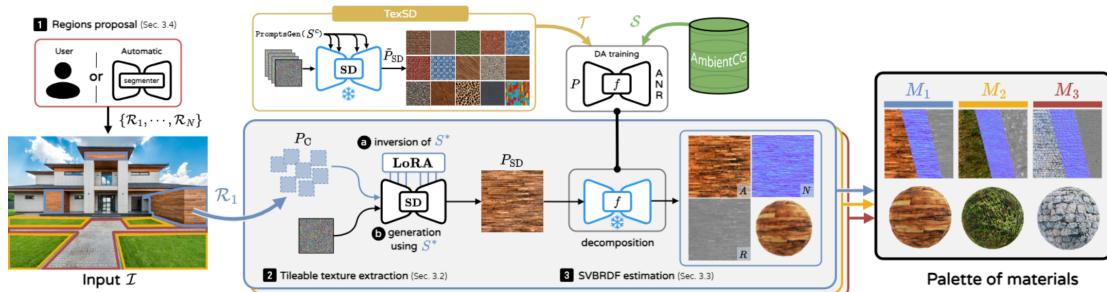


Imagen 3.7: As etapas de processo de Material Palette

3.5 “Curso de Stable Diffusion”

Autor: Tiago O Luz (2023)

Fontes: GitHub

Resumos: este projeto [9] disponível no GitHub oferece material didático sobre uso de Stable Diffusion, incluindo notebooks para executar modelos em GPUs e no Google Colab. A apresentação inicial mostra o passo a passo para execução do Stable Diffusion, além de apresentar brevemente os exemplos de formas de uso como text-to-image, image-to-image, inpainting e ControlNet. Em seguida, apresenta o fluxo de trabalho que inicia detalhando a construção de prompt (sujeito, estilo, sites, artistas, resolução, cor, prompt negativo e entre outros), escolha de *sampler*, números de passos, opções de pesos no prompt, CFG Scale para ajustar a influência dos prompt e melhorar qualidade com *upscaling*. Por fim, a segunda apresentação mostra como utilizar a nova ferramenta que permite incluir novos conceitos sem terminar a rede neural chamada LoRA. Basicamente permite agregar conceitos novos a um modelo, ou seja, em vez de treinar o modelo completo novamente, LoRA ajusta apenas algumas partes pequenas e específicas do modelo (personagem, estilo, ação etc.). Ainda mais detalhado as funcionalidades específicas sobre o ControlNet, o qual é uma extensão do Stable Diffusion que permite maior controle sobre a geração de imagem específica através de camada adicional de controle. Ele oferece as técnicas como canny egde, HED egde, Depth áreas, scribbles, normal map, open pose bone, segmentation e M-LSD line. Essas técnicas realizam funções como detecção de bordas, profundidades, poses, segmentos de linha e divisão de objetos ou regiões. Portanto, essas informações podem auxiliar o uso mais proveitoso e eficiente das ferramentas, permitindo maior criatividade e possibilitando aos desenvolvedores explorar e experimentar diferentes conceitos visuais para criação de jogo, como ideias de personagens e de ambientes de jogo.

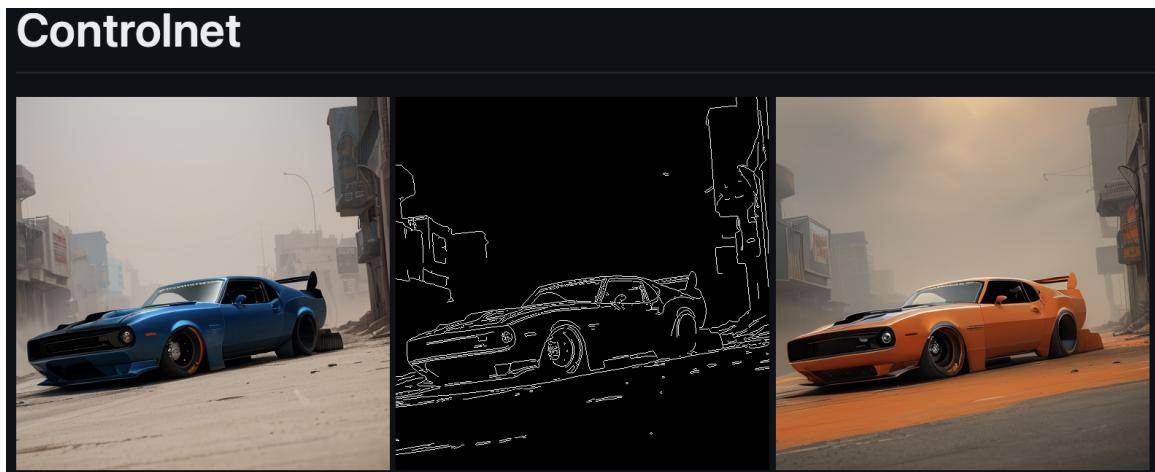


Imagen 3.8: Exemplo de geração de imagem de carro utilizando Control Net

3.6 “Creating 3D Parallax Type Images With Automatic1111 Stable Diffusion WebUI & Depth Maps”

Autor: Prompting Pixels (2024)

Fonte: Medium

Resumo: este artigo [10] divulgado no Medium apresenta tutorial sobre a criação de efeitos paralaxe ou animação 3D que demonstra profundidade e movimento de uma imagem, utilizando WebUI de Stable Diffusion. Primeiramente, instala no Stable Diffusion a extensão de Depth Map Script, podendo escolher entre vários modelos, como MiDaS, LeReS ou ZoeDepth. Assim, gera a imagem de profundidade, muito similar com depth de ControlNet. Para obter efeito paralaxe precisa de uma malha 3D que é gerada a partir de mapa de profundidade, para isso necessário ativar a opção de “*generate 3D inpaint mesh*”. O arquivo gerado será .obj que é utilizado para gerar vídeo .mp4 a partir dele, nesse arquivo está contido além de malha 3D, outras informações que são necessários para processo subsequente. Por fim, para gerar o vídeo que simula o movimento da câmera na cena como um efeito de zoom, precisa ativar a opção de “*generate 4 demo videos with 3D inpainted mesh*”.

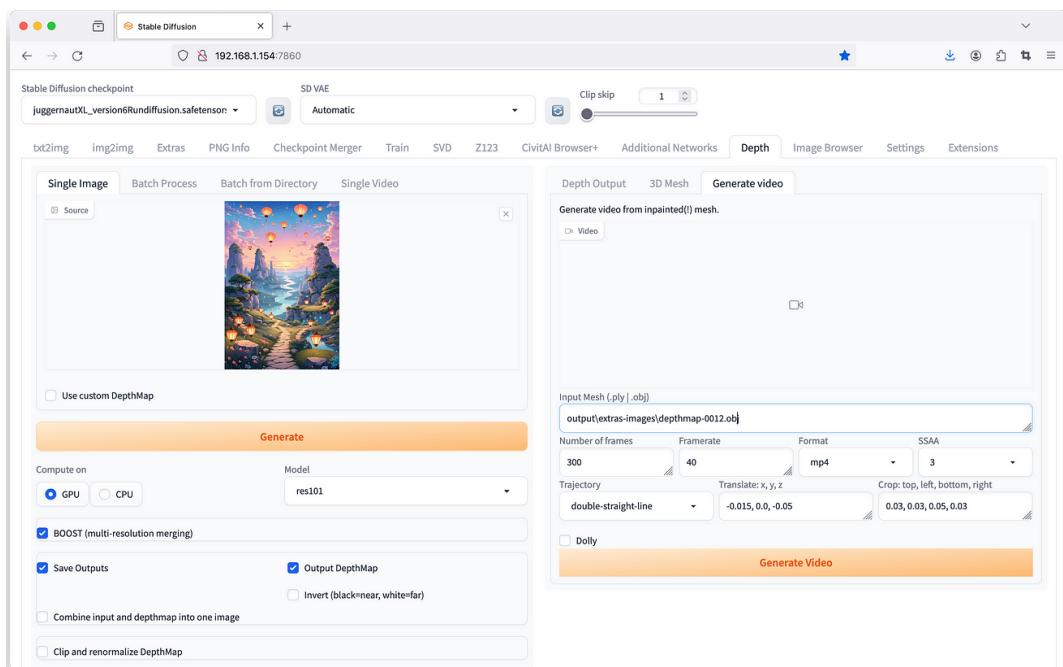


Imagen 3.9: Exemplo de geração de vídeo com efeito de profundidade

Dessa maneira, o vídeo pode auxiliar na criação de cena do jogo a partir de uma imagem. No entanto, há grande limitação como quando o sujeito está muito próximo, pode ocorrer um “rasgamento” da imagem, assim separando ou distorcendo, e causando em uma aparência não natural. Para minimizar esse problema, recomenda-se que o sujeito esteja mais afastado.

3.7 “Image to 3D - 3D AI generation for GameDev Experiment”

Autor: Maria Zatorska (2024)

Fonte: ArtStation

Resumo: este artigo [11] apresenta o tutorial de geração de modelagem 3D a partir de uma imagem para desenvolvimento de jogo utilizando IA gerativa, divulgado em ArtStation. Na primeira etapa, o autor realizou a geração de imagem frontal e de traseira de uma personagem com DALL-E, pois, permite ajustar os resultados com linguagem natural e a edição no Photoshop com recurso gerado pela IA permitindo as correções precisas e pinturas. Na segunda etapa, utilizou [CSM.ai](#) para geração de modelagem 3D, segmentando em partes e gerando-as separadamente, assim resultando em melhor detalhamento de cada parte, como mostrado na Imagem 3.10. Algumas peças, nesse caso os olhos robóticos foram gerados usando Tripo3d.ai.



Imagen 3.10: Geração de peça 3D partir de uma imagem no CSM.ai

Em seguida, realizou retopologia no Blender com uso de QuadRemesh ou ferramenta de remesh do Blender, para ajuste e correção do problema no modelo. E ainda no modo escultura, usou Filter Brush para suavização da superfície do modelo. Além disso, aplicou o mapa de cores gerados pela IA na nova malha retopolizada com UV. Na última etapa, com Substance Sampler do Adobe para criar materiais PBR a partir de mapas de cor gerados por IA. Assim, podendo criar personagens e objetos 3D de forma mais eficiente e simples. O tutorial detalhado está no seguinte vídeo: [YouTube](#).

3.8 “Creating Procedural Materials Using AI & Substance 3D Designer”

Autor: Giuseppe Alfano (2023)

Fonte: 80lv

Resumo: este artigo [12] mostra o fluxo de criação de material a partir de imagens geradas por Stable Diffusion. O autor queria otimizar o fluxo de trabalho para reduzir o tempo desperdiçado em tarefas repetitivas, assim se interessou em capacidade de roteirizar IA para gerar um grande número de materiais a partir de uma entrada de texto simples. Para gerar imagem de textura, usou prompt padrão de “*Top Down Photo of \$Subject*”, por exemplo se quer gerar um material de solo rochoso digita “*Top Down Photo of a Rocky Ground*”, como mostrado na Imagem 3.11. A partir disso, pode começar a acrescentar outras informações ao prompt para adicionar detalhes ou expandir os resultados. Em seguida, realizou mistura de dois ou mais texturas geradas no Substance 3D Designer, obtendo muito mais variação e controle sobre o material final. Para melhor resultado de geração de mapas, o autor realiza upscaling, aumentando a imagem para uma muito mais detalhada. E por fim, para renderizar imagem final utilizou Marmoset Toolbag4 que é rápido, poderoso e fácil de usar.

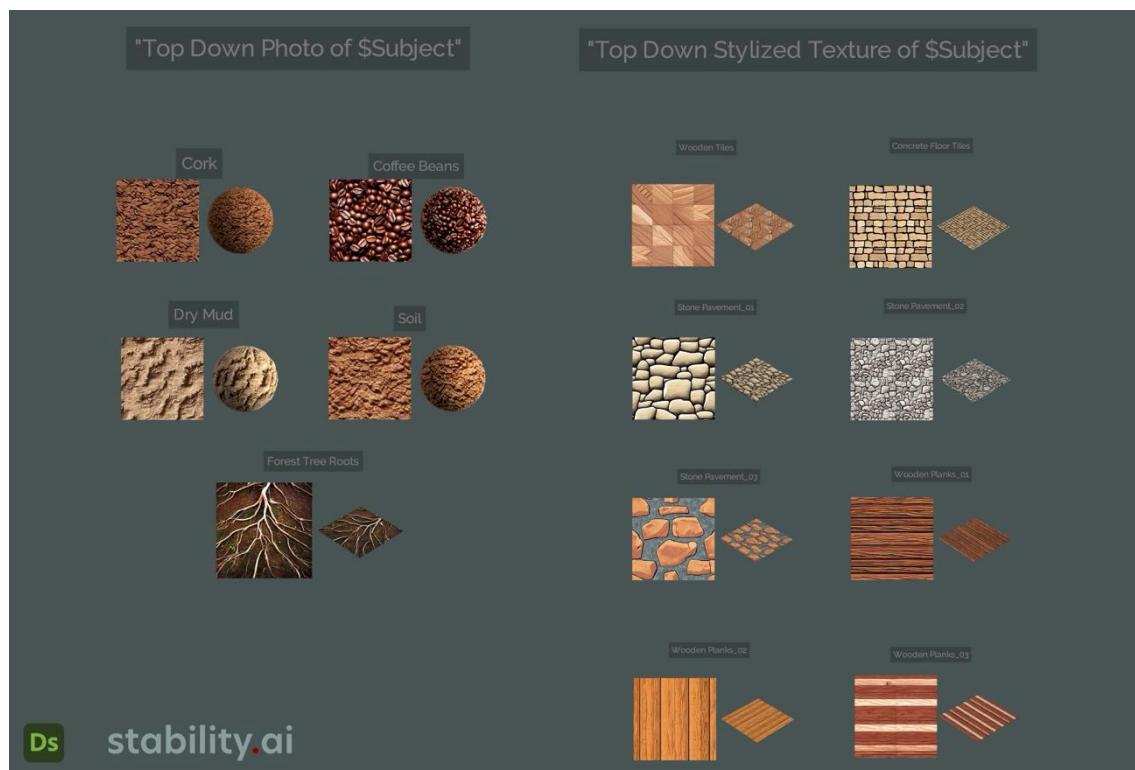


Imagen 3.11: Exemplos de texturas e materiais geradas

3.9 “Meshy AI : a 3D AI Model Design Generator”

Autor: Gioxyer (2024)

Fonte: Medium

Resumo: neste artigo [13] apresenta o [Meshy AI](#), um gerador de design de modelos 3D. Meshy é a ferramenta de IA generativa 3D para criar sem esforço ativos 3D a partir de texto ou imagens, acelerando o fluxo de trabalho 3D, com ele, pode criar texturas e modelos 3D de alta qualidade em minutos. Primeiramente, o autor apresenta imagem para textura, essa técnica cria textura a partir de imagem de arte conceitual, em menos de 10 minutos, como pode observar em Imagem [3.12](#). O próximo seria texto para 3D, que a partir de prompt detalhado gera modelagem 3D texturizada dentro de 2 minutos. E por último, imagem para 3D que cria modelo 3D totalmente texturizado com apenas uma única imagem, como mostrado na Imagem [3.13](#).

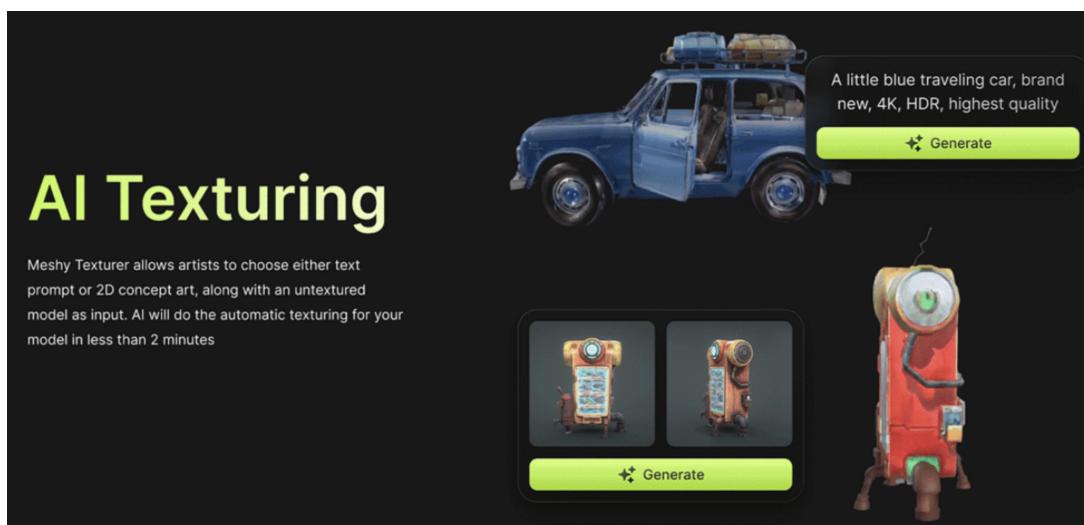


Imagen 3.12: Exemplo de imagem para textura com Meshy AI

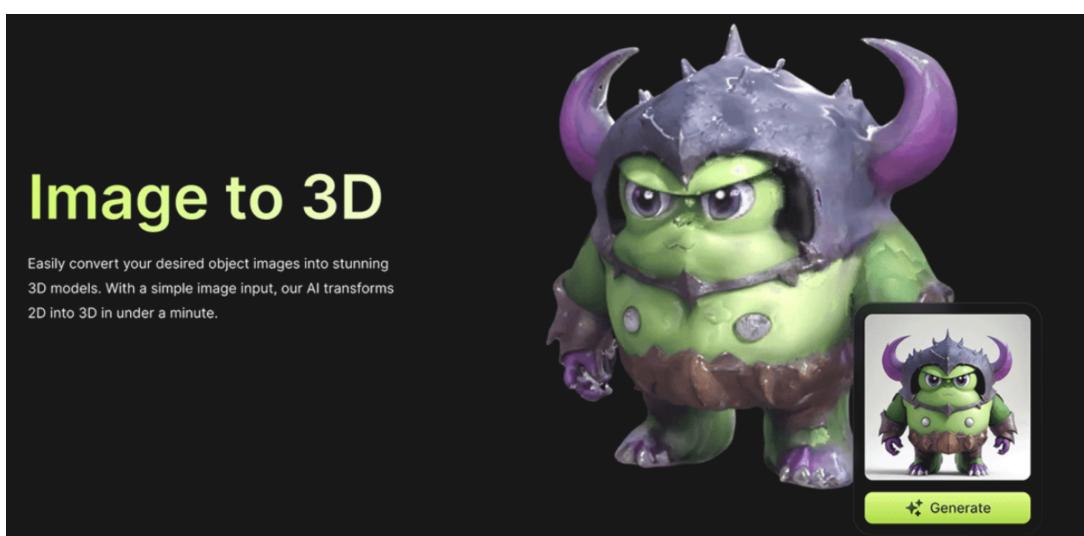


Imagen 3.13: Exemplo de imagem para 3D com Meshy AI

3.10 “Luma Genie 3D Character”

Autor: Luma AI (2023)

Fonte: Luma Community

Resumo: este artigo [14] da Luma Community apresenta ferramenta de IA gerativa [Luma Genie](#) que cria objeto ou personagem 3D a partir de um prompt de texto. Apresentando o processo detalhado como uma ideia simples pode se transformar em personagem de jogo. Inicia com prompt de texto no Genie da Luma AI, no exemplo utiliza “*long-legged astronaut rabbit*”, assim Genie gera 4 modelos 3D e se necessitar pode refinar uma da selecionada, como está apresentada na Imagem 3.14. Depois de selecionar, baixou em arquivo FBX (pode-se escolher outros formatos) e utilizou Acurig que é um aplicativo de manipulação de caracteres. É intuitivo e gratuito. Assim, podendo definir as articulações e membros do personagem, em seguida aplicando movimento nessa personagem. Por último, importa a personagem no Unreal Engine, garantindo as configurações corretas do esqueleto. Substituiu o personagem padrão do jogo pela personagem criada e ajusta a classe de animação. Este processo mostra potencial da IA na criação de personagem, além de ser eficiente e pode ser totalmente automatizado no futuro.

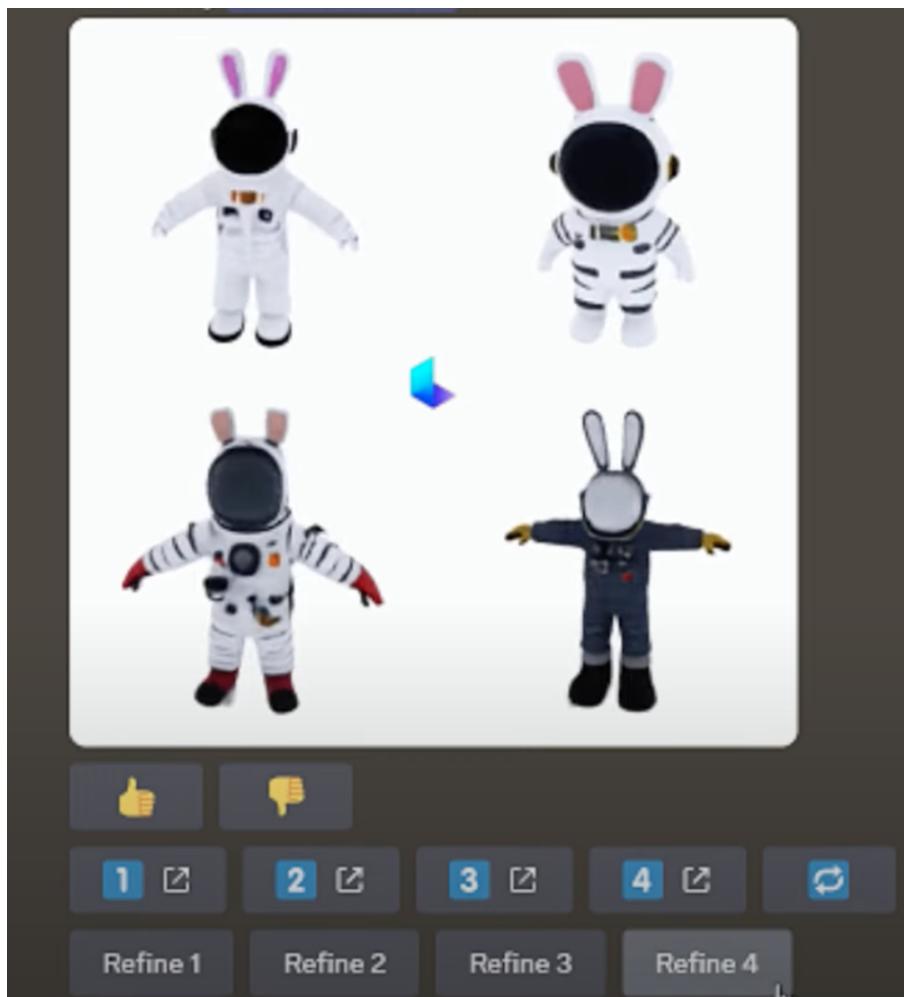


Imagen 3.14: Modelos 3D gerados com prompt no Genie da Luma AI

3.11 “How Upland Accelerated Their 3D Asset Production by 70%”

Autor: Kaedim

Fonte: Medium

Resumo: este artigo [15] apresenta os benefícios que ferramenta de IA chamado [Kaedim](#) trouxe para Upland acelerar produção de ativos em 70%, essa ferramenta transforma imagem em modelos 3D. Upland é uma plataforma de metaverso baseada em blockchain que enfrentava desafios significativos com grande demanda por novos ativos 3D. No artigo mostra passo a passo de transformação de imagem de arte conceitual para modelo 3D. Primeiramente, cria conceitos iniciais com IA gerativa como Stable Diffusion, como a Imagem [3.15](#). Logo depois, utiliza imagem gerada como entrada no Kaedim AI e gera malha texturizada, como mostrado na Imagem [3.16](#). Assim, importa esse modelo 3D em Blender e realiza ajustes e correções finais. Portanto, o processo simplificado de produções de ativos abre novos caminhos para os criadores, reduzindo significativamente o tempo necessário para transformar uma ideia em modelo finalizado.



Imagen 3.15: Imagem gerada através de prompt com Stable Diffusion



Imagen 3.16: Modelo 3D gerada partir de uma imagem no Kaedim

4. CONCLUSÃO

A revisão sistemática realizada sobre uso de IA gerativa na modelagem 3D aplicada no desenvolvimento de jogos revelou significativos avanços tecnológicos e metodológicos que prometem transformar a indústria de entretenimento. Os principais benefícios incluem maior eficiência, criatividade aprimorada e redução de tempo de criação. A adoção dessas tecnologias pode alterar os fluxos de trabalho dos desenvolvedores de jogos e ampliar as possibilidades criativas, sem a necessidade de habilidades artísticas avançadas ou experiência com modelagem.

Contudo, esta revisão sistemática também reconhece as limitações e desafios associados ao uso da IA gerativa, como a qualidade dos dados de treinamento, falta de precisão e controle criativo, alta demanda por recursos computacionais, tempo de processamento, propensão a falhas e inconsistência e o risco de plagiar designs existentes. Portanto, o reconhecimento das limitações é crucial para desenvolver estratégias eficazes que maximizem os benefícios da IA gerativa enquanto mitigam seus desafios.

Em conclusão, existem inúmeras ferramentas e métodos de IA gerativa apresentados que podem auxiliar de forma eficiente na criação de modelos 3D para serem utilizados no desenvolvimento dos jogos, com potencial de revolucionar a criação de conteúdo na indústria de jogos. Para aproveitar ao máximo e para obter mais controle é necessário ter mais tutoriais detalhadas sobre o uso dessas ferramentas e métodos.

5. REFERÊNCIAS

- [1] Yichun Shi, Peng Wang, Jianglong Ye, Long Mai, Kejie Li, Xiao Yang. “MVDream: Multi-view Diffusion for 3D Generation” (2024) URL: <https://arxiv.org/pdf/2308.16512>
- [2] Nataniel Ruiz, Yuanzhen Li, Varun Jampani, Yael Pritch, Michael Rubinstein e Kfir Aberman. “DreamBooth: Fine Tuning Text-to-Image Diffusion Models for Subject-Driven Generation” (2023) URL: <https://arxiv.org/abs/2208.12242>
- [3] Minghua Liu, Ruoxi Shi, Linghao Chen, Zhuoyang Zhang, Chao Xu, Xinyue Wei, Hansheng Chen, Chong Zeng, Jiayuan Gu e Hao Su. “One-2-3-45++: Fast Single Image to 3D Objects with Consistent Multi-View Generation and 3D Diffusion” (2023) URL: <https://arxiv.org/abs/2311.07885>
- [4] Minghua Liu, Chao Xu, Haian Jin, Linghao Chen, Mukund Varma T e Hao Su. “One-2-3-45: Any single image to 3d mesh in 45 seconds without per-shape optimization” (2023) URL: <https://arxiv.org/abs/2306.16928>
- [5] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov e Carl Vondrick. “Zero-1-to-3: Zero-shot One Image to 3D Object” (2023) URL: <https://arxiv.org/abs/2303.11328>
- [6] Chenjian Gao, Boyan Jiang, Xinghui Li, Yingpeng Zhang e Qian Yu. “GenesisTex: Adapting Image Denoising Diffusion to Texture Space” (2024) URL: <https://arxiv.org/abs/2403.17782>
- [7] Ivan Lopes, Fabio Pizzati e Raoul de Charette. “Material Palette: Extraction of Material from Single Image” (2023) URL: <https://arxiv.org/abs/2311.17060>
- [8] Edward Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang e Weizhu Chen. “LORA: LOW-RANK ADAPTATION OF LARGE LANGUAGE MODELS” (2021) URL: <https://arxiv.org/abs/2106.09685>
- [9] Tiago O Luz. “Curso de Stable Diffusion” (2023). URL: <https://github.com/Tiago-O-Luz/StableDiffusionKit/tree/main?tab=readme-ov-file>
- [10] Prompting Pixels. “Creating 3D Parallax Type Images With Automatic1111 Stable Diffusion WebUI & Depth Maps” (2024) URL: <https://medium.com/@promptingpixels/creating-3d-parallax-type-images-with-automatic1111-stable-diffusion-webui-depth-maps-3eff02cf4449>
- [11] Maria Zatorska. “Image to 3D – 3D AI generation for GameDev Experiment” (2024) URL: <https://www.artstation.com/blogs/marizatorska/YQbB3/image-to-3d-3d-ai-generation-for-gamedev-experiment>
- [12] Giuseppe Alfano. “Creating Procedural Materials Using AI & Substance 3D Designer” (2023) URL: <https://80.lv/articles/creating-procedural-materials-using-ai-substance-3d-designer/>
- [13] Gioxyer. “Meshy AI: a 3D AI Model Design Generator” (2024) URL: <https://medium.com/@xclip.gioxyer/meshy-ai-3d-model-design-generator-90bd26a38859>

[14]Luma Community. “Luma Genie 3D Character” (2023) URL: <https://www.luma-ai.com/luma-genie-3d-character/>

[15]Kaedim. “How Unpland Accelerated Their 3D Asset Production by 70%” (2023) URL: <https://medium.com/kaedim/how-upland-accelerated-their-asset-production-by-70-15ac008ab196>